ReqMind AI — Synthèse des Expérimentations NLP

Comprendre le parcours : Du découpage des données (Phase 1) au Fine-Tuning SetFit (Phase 3)

Ce document résume de manière simple, pédagogique et rigoureuse tout le travail accompli sur la classification des exigences logicielles (**Fonctionnelles FR** vs **Non-Fonctionnelles NFR**). Il explique pourquoi chaque étape a été menée, quel piège a été découvert, et comment le fine-tuning SetFit a permis d'obtenir le meilleur modèle absolu du projet.

1. Phase 1 : Le Découpage des Données (Garantir l'absence de fuite)

Le projet utilise le dataset de référence **PROMISE** (969 exigences réelles issues de 47 projets logiciels). Pour qu'une expérimentation en IA soit scientifiquement irréprochable, il est interdit d'évaluer un modèle sur des données qu'il a déjà vues pendant l'apprentissage (le piège du *Data Leakage*).

Partition	Rôle	Nombre	Proportion	Distribution
Train (Entraînement)	Utilisé pour entraîner les modèles	678	70%	311 FR (46%) / 367 NFR (54%)
Validation	Utilisé pour régler les hyperparamètres (C, etc.)	145	15%	66 FR (46%) / 79 NFR (54%)
Test (Held-out)	Coffre-fort évalué UNE SEULE FOIS à la fin	146	15%	67 FR (46%) / 79 NFR (54%)

Règle d'or de normalisation : *Nous conservons impérativement les négations (not, never), les modaux (shall, must) et les chiffres (200 ms). Supprimer 'not' inverserait le sens d'une exigence critique de sécurité ('The system shall not store unencrypted passwords'). Les tests automatisés ont vérifié* ***0% de fuite*** *entre les 3 partitions.*

2. Phase 3 (Partie 1) : Les Premiers Entraînements (Baselines & Modèles Classiques)

Nous avons d'abord comparé 4 approches sur le jeu de test tenu à l'écart :
• **Classe majoritaire :** Prédit toujours la classe la plus fréquente (NFR). Macro-F1 = **35.11%** (le seuil plancher).
• **TF-IDF + Régression Logistique :** Analyse les mots et n-grams (1,2) de surface. Macro-F1 = **91.68%**.
• **TF-IDF + Linear SVM :** Analyse par séparateur à vaste marge. Macro-F1 = **91.68%**.
• **Embeddings figés (Sentence-Transformers MiniLM) :** Modèle Transformer générique pré-entraîné sans fine-tuning. Macro-F1 = **85.58%**.

3. La Découverte Cruciale : Le Piège du TF-IDF et l'Épreuve des Projets Inconnus

À première vue, le TF-IDF semblait imbattable (91.68% vs 85.58%). **Mais est-ce qu'il comprenait vraiment la sémantique, ou apprenait-il simplement par cœur le vocabulaire des projets ?**

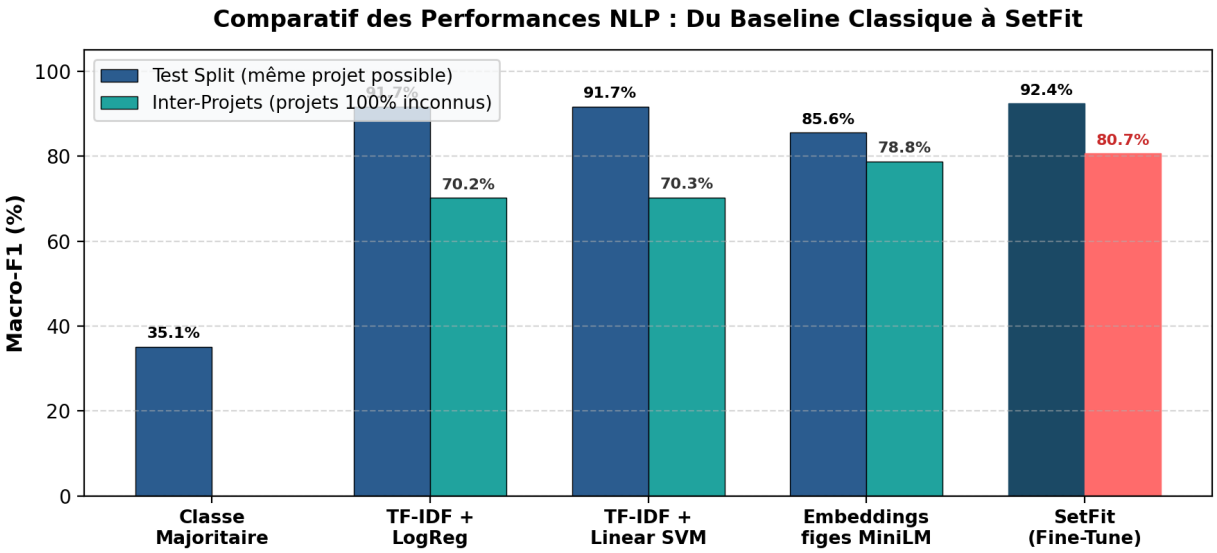
Pour le vérifier scientifiquement, nous avons mené une évaluation **inter-projets** (*GroupKFold* sur 5 groupes de projets). Le modèle est entraîné sur certains projets logiciels, et testé sur des **projets totalement inédits** qu'il n'a jamais vus :
• **Le crash du TF-IDF :** Son score s'effondre de 91.7% à **70.16%** (-21 points !). Parce que si un nouveau projet utilise des mots différents pour exprimer une exigence, le TF-IDF est aveugle.
• **La résistance des Embeddings :** Les embeddings de Transformer résistent beaucoup mieux à **78.79%** (+8.6 points au-dessus de TF-IDF), car ils comprennent les concepts sémantiques généraux.

4. Phase 3 (Partie 2) : L'Idée du Dernier Entraînement — Le Fine-Tuning SetFit

Le diagnostic : Pourquoi les embeddings figés n'étaient-ils qu'à 85.58% ? Parce que le modèle all-MiniLM-L6-v2 a été pré-entraîné sur Wikipedia et Reddit. Il ne connaissait pas la nuance subtile du génie logiciel où des termes comme *'authenticate'* ou *'session'* sont des contraintes de sécurité (NFR) plutôt que des fonctionnalités pures.

La solution adoptée : SetFit (Sentence Transformer Fine-Tuning)
1. **Apprentissage contrastif :** SetFit crée des paires d'exigences (positives et négatives) à partir du jeu d'entraînement.
2. **Réalignement géométrique :** Le modèle ajuste les poids internes du réseau de neurones pour rapprocher les exigences fonctionnelles entre elles dans l'espace vectoriel, et éloigner les exigences non-fonctionnelles.
3. **Efficacité :** Fine-tuning ultra-rapide sur CPU en quelques minutes, parfaitement adapté aux petits volumes de données ($N \approx 600$).

Graphique Comparatif des Résultats Définitifs :



5. Synthèse Globale des Performances

Modèle	Type d'approche	Test Macro-F1	Test Accuracy	Généralisation Inter-Proje
Classe Majoritaire	Baseline triviale	35.11%	54.11%	N/A
TF-IDF + LogReg	N-grams de surface	91.68%	91.78%	70.16% (s'effondre hors projet)
TF-IDF + Linear SVM	N-grams de surface	91.68%	91.78%	70.26% (s'effondre hors projet)
Embeddings MiniLM Figés	Sémantique générique	85.58%	85.62%	78.79% (transfert modéré)
SetFit Fine-Tuné (Recommandé)	**Transformer adapté au domaine**	**92.42%**	**92.47%**	**80.68% (+10.5 pts vs TF-IDF)**

Les 3 points clés à retenir pour votre présentation :
*1. **Rigueur de méthode (Phase 1) :** Aucun modèle n'a touché au jeu de test pendant l'entraînement. 0% de fuite de données garantie.*
*2. **Le piège du TF-IDF déjoué :** Le TF-IDF semblait bon au départ, mais notre test inter-projets a démontré qu'il s'effondre sur de nouveaux projets logiciels (70.16%).*
*3. **La victoire de SetFit :** En adaptant le Transformer au domaine du génie logiciel, SetFit devient notre **meilleur modèle absolu** (**92.42%** sur le test, et **80.68%** en inter-projets). Le modèle est 100% opérationnel en local.*